PRÁCTICA 1

Munguia Gallegos Mauricio.

viernes 30/08/2019.

INSTITUTO POLITÉCNICO NACIONAL

UNIDAD PROFESIONAL INTERDISCIPLINARIA EN

INGENIERÍA Y TECNOLOGÍAS AVANZADAS

3BV2

ASIGNATURA: ELECTRÓNICA ANALOGICA Y DE POTENCIA

Marco Teórico

Distancia euclídea: En matemáticas, álgebra, geometría y, más específicamente, en análisis real, análisis complejo y geometría analítica, se trata de una función no negativa usada en diversos contextos para calcular la distancia entre dos puntos , primero en el plano y luego en el espacio. También sirve para definir la distancia entre dos puntos en otros tipos de espacios de tres o más dimensiones. Y para hallar la longitud de un segmento definido por dos puntos de una recta, del plano o de espacios de mayor dimensión.

Sus bases se encuentran en la aplicación del Teorema de Pitágoras sobre triángulos rectángulos, donde la distancia euclidiana viene a ser por lo general la longitud de la hipotenusa del triángulo recto conformado por cada punto y los vectores proyectados sobre los ejes directores al nivel de la hipotenusa.

En el plano cartesiano sean los puntos A=(xA;yA) B=(xB;yB) se define la distancia euclidiana entre dichos puntos por:

- $d(A,B)=\sqrt{(x_B-x_A)^2+(y_B-y_A)^2}$

Y de manera más general en un espacio de N dimensiones la distancia euclideana entre dos puntos A=(a1;a2;...;aN) y B=(b1;b2;...;bN) se ajusta a:

- $d(A,B)=\sqrt{\sum_{i=1}^{N}(b_i-a_i)^2}=\sqrt{(b_1-a_1)^2+(b_2-a_2)^2+\ldots+(b_N-a_N)^2}$

La **distancia de mahalanobis** es una medida de distancia introducida por Mahalanobis en 1936. Su utilidad radica en que es una forma de determinar la similitud entre dos variables aleatorias multidimensionales. Se diferencia de la distancia euclídea en que tiene en cuenta la correlación entre las variables aleatorias

Para entender la utilidad de la distancia de Mahalanobis, se puede considerar el siguiente ejemplo práctico: Un pescador quiere poder medir la similitud entre dos salmones, porque quiere clasificarlos en dos tipos para su venta y poder así vender los grandes más caros. Para cada salmón mide su anchura y su longitud. Con estos datos construye un vector $x_i = (x_{1i} + x_{2i})$ para cada salmón i.

La longitud de los salmones pescados es una variable aleatoria que toma valores entre 50 y 100 cm, mientras que su anchura está entre 10 y 20 cm. Si el pescador usase la distancia euclídea: $d = \sqrt{(x1 - x2)^2 + (y1 - y2)^2}$

Al ser las diferencias de anchura menos grandes que las de longitud, les estará dando menos importancia. Por esta razón, el pescador decide incorporar la estadística de los datos a la medida de distancia, ponderando según su varianza; las variables con menos varianza tendrán más importancia que las de mayor varianza. De esta forma pretende igualar la importancia de la anchura y la longitud en el resultado final. La expresión quedaría:

$$d = \sqrt{((x11 - x12)/\sigma 1)^2 + ((x21 - x22)/\sigma 2)^2}$$

Donde $\sigma 1$ es la varianza de la componente i de los vectores de medidas. O en notación vectorial:

$$d = \sqrt{(x1 - x2)^T S^{-1} (x1 - x2)}$$

Donde S es la matriz de covarianza

El método de los **k vecinos** más cercanos (en inglés, k-nearest neighbours, abreviado knn) es un método de clasificación supervisada.

Normalmente es usada como análisis preliminar de los datos (resumen, características de los datos, casos extremos, etc.). Con esto, el usuario se sensibiliza con los datos y su estructura. Busca derivar descripciones concisas de caracterısticas de los datos (e.g., medias, desviaciones estándares, etc.).

Las reglas de clasificación por vecindad están basadas en la búsqueda en un conjunto de prototipos de los k prototipos más cercanos al patrón a clasificar.

Los ejemplos de entrenamiento son vectores en un espacio característico multidimensional, cada ejemplo está descrito en términos de p atributos considerando q clases para la clasificación. Los valores de los atributos del i-ésimo ejemplo (donde $1 \leq i \leq n$) se representan por el vector p-dimensional.

El espacio es particionado en regiones por localizaciones y etiquetas de los ejemplos de entrenamiento. Un punto en el espacio es asignado a la clase C si esta es la clase más frecuente entre los k ejemplos de entrenamiento más cercano. Generalmente se usa la distancia euclidiana.

Desarrollo

Primero se hizo un programa el cual automáticamente generaba las clases existentes de una imagen mediante un método “intuitivo” el cual consiste en ver que tan cercanos eran los puntos de pixel entre los centros de las clases, si la distancia era mayor al del umbral asignado generaba una nueva clase, éste programa se hizo como una función que retorna un diccionario, la estructura de este diccionario es:

```
{
        “class0”:  [
                (rrr,ggg,bbb), [
                        (rrr,ggg,bbb), (rrr,ggg,bbb),(rrr,ggg,bbb)
                ]
        ]
}
```

donde la llave es el número de la classe empezando desde 0 y llegando hasta un n, y el valor es una lista que contiene como primer elemento el centro de la clase y su segundo elemento es una lista que contiene todos los valores que constituyen a la clase. Como última acción relacionada con el creador de clases se creó un módulo para su fácil uso mediante importación

Para la máquina euclidiana primeramente se hizo una función para calcular la distancia euclídea entre dos puntos de 3 valores y al igual que en el generador de clases se creó un módulo para poder importar la función de la distancia euclídea.
Ya teniendo la función y el generador de clases se hizo un script el cual mandaba a llamar estas dos funciones y primero te obtenía el diccionario de las clases después iteramos sobre la imagen y por cada pixel de la imagen sacamos la distancia euclídea con respecto al centro de las clases y con el centro que obtuviera la menor distancia euclídea asignamos el pixel a esa clase la cual tendrá un color específico, al final de este programa ploteamos la nueva matriz creada por la máquina euclídea.

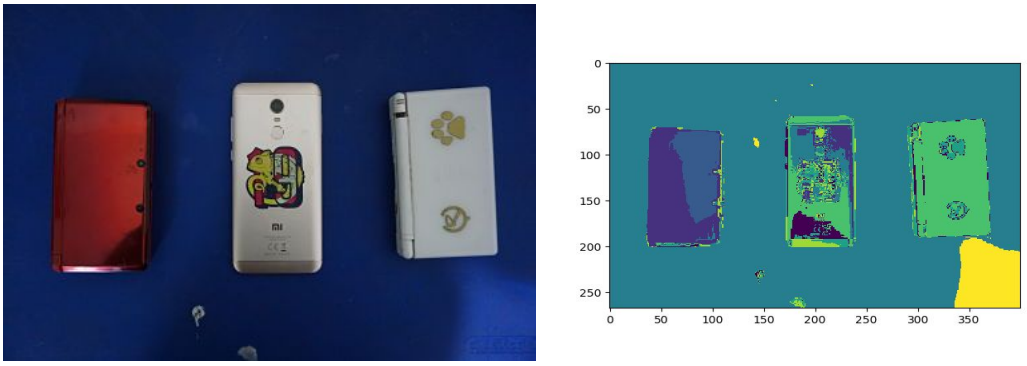

Fig 1: Con esta imagen se generaron las clases para la máquina euclidiana.

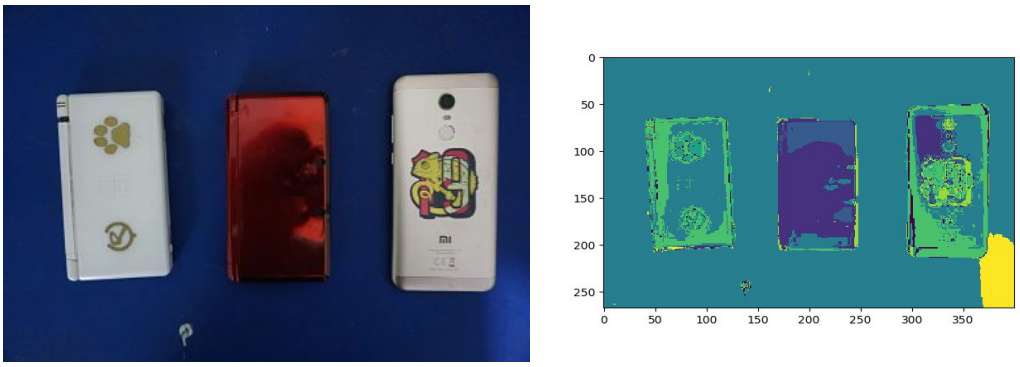

Fig 2: Con esta imagen se probaron las clases anteriormente creadas.

En cuanto a la máquina de mahalanobis se procedió de la misma forma, se creó una función la cual nos calculaba la distancia mahalanobis y de igual manera se guardó en el mismo módulo que el de la distancia euclidiana para poder importarla y poder hacer uso de ella de manera más sencilla. Para la obtención de puntos no sé logró hacer un script para automatizar el proceso así que se decidió que el usuario eligiera 4 clases y con un for ir ploteando ginputs para la obtención de los datos prueba para cada clase.
Después de la obtención de puntos de cada clase se iteró sobre la imagen, calculamos la distancia mahalanobis y la distancia con respecto a la clase que fuera menor se le asignaba el pixel de muestreo para que al final plotearamos la matriz resultante como imágen.

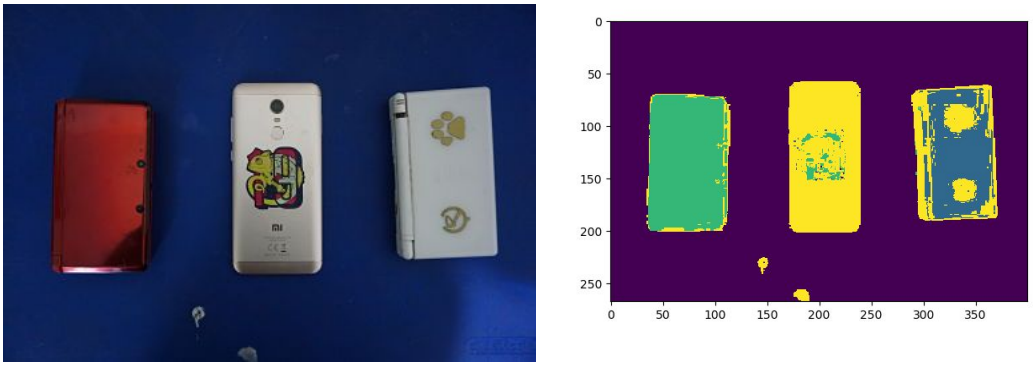

Fig 3: Con esta imagen se generaron las clases para la máquina mahalanobis

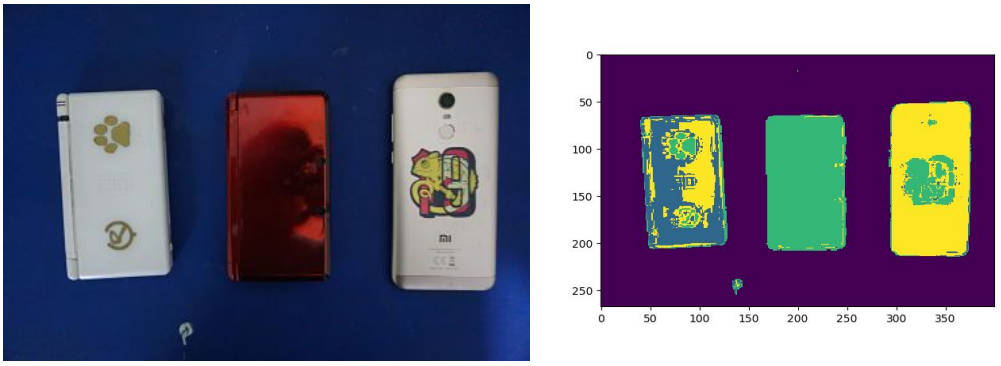

Fig 4: Con esta imagen se probaron las clases anteriormente creadas.

Por último se programó el algoritmo para knn y se decidió usar distancia euclídea para la distancia entre vecinos, se fijó una k igual a 3 y al igual que en la máquina euclidiana se importó el generador de clases intuitivo para que nos generará las clases y así iterar sobre la imagen y sacar la distancia euclídea con todos los puntos de las clases y al final asignar el pixel de muestreo a la clase que tuviera más puntos cercanos de los 3 disponibles sujetos por la k.

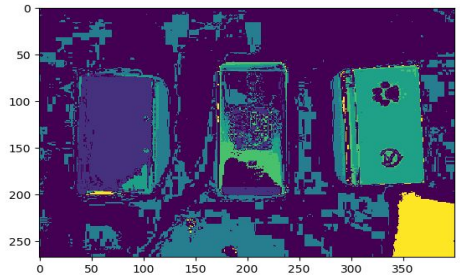

Fig 5: Con esta imagen se generaron las clases para el algoritmo knn

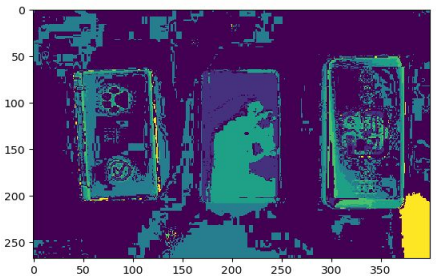

Fig 5: Con esta imagen se probaron las clases anteriormente creadas.

Conclusiones

En cuanto a velocidad fue más rápido la máquina euclidiana, después knn con distancia euclidiana y al final mahalanobis pero como las pruebas lo muestran la clasificación fue mucho mejor usando distancia mahalanobis.

Cuando se usó el generador de clases intuitivo las sombras generaban nuevas clases y al momento de hacer la clasificación la imagen se veía “distorsionada” ya que las sombras hacían que el objeto se pintara de otro color, pero en el momento de que lo hacías manualmente como se hizo en la distancia mahalanobis tenías la oportunidad de agregar las sombras de cada objeto a los puntos de las clases y así resultaba una mejor clasificación.